实验要求不使用 PyTorch / TensorFlow 等深度学习框架，仅基于 NumPy

数据解析与预处理：

在 dataset.py 中，我实现了 EuroSATDataset 类，用于自动读取 EuroSAT_RGB 目录下的 10 个地物类别，并将类别名按字母序建立到索引的映射（ class_to_idx ），从而保证标签编码稳定一致。

数据划分方面，我将完整数据集按 80% 训练集、10% 验证集、10% 测试集 的比例进行随机划分，并固定随机种子以保证划分可复现。为配合卷积神经网络的输入需求，我将输入图像统一处理为 224×224 分辨率（可通过参数调整），并采用与 ImageNet 预训练模型一致的归一化策略（mean = (0.485, 0.456, 0.406)， std = (0.229, 0.224, 0.225)），以减少分布偏移并加速收敛。

在训练集上，我引入了更全面的数据增强以提升泛化能力，包括：随机缩放裁剪（RandomResizedCrop，scale 在 0.7 到 1.0 之间）、随机水平/垂直翻转、随机旋转（20 度）、轻度颜色扰动（ColorJitter），并在归一化后增加随机擦除（RandomErasing）。验证集与测试集仅进行 Resize 与归一化，不做随机增强，以保证评估结果稳定可信。

模型构建：

在 train.py 中，我实现了完整的训练、验证、最优模型保存与最终测试评估流程，并将默认训练轮数提升到 150 个 Epoch。训练过程中，我以验证集准确率作为选择指标：当某一轮的验证准确率超过历史最佳值时，立即保存当前权重到 best_model.pth ，确保最终测试使用的是验证集上表现最优的模型，而不是最后一轮的权重。

优化器方面，我采用 AdamW （学习率默认 3e-4，权重衰减默认 1e-4），以获得更稳定的收敛与更合理的权重正则化效果。学习率调度策略采用 CosineAnnealingLR ，在整个训练周期内以余弦退火方式平滑下降学习率，有利于中后期精细收敛并提升最终精度。

损失函数使用带 Label Smoothing（0.1） 的交叉熵损失，以降低过度自信预测带来的过拟合风险，从而提升模型在测试集上的泛化表现。此外，在支持 CUDA 的环境下，我启用了自动混合精度（AMP）进行训练，以降低显存占用并提高训练吞吐；该策略不改变模型结构与目标函数，原则上不会降低最终精度，且能在多数情况下提升训练效率。

训练逻辑实现：

在 train.py 中配置了优化后的超参数：

训练时长：增加至 20 个 Epoch，确保深层模型充分学习。

优化器：使用带动量的 SGD(Momentum=0.9)。

正则化：结合了 L2WeightDecay(1e-4)和 Dropout 策略。

学习率策略：使用 StepLR 调度器，每 7 个 epoch 衰减为原来的 0.1。

评估与可视化：

训练完成后，我加载验证集准确率最优的模型权重 best_model.pth ，并在测试集上进行一次完整评估。数据集按照 80% 训练、10% 验证、10% 测试 的比例随机划分，并固定随机种子为 42 以保证划分可复现；测试集评估阶段不使用随机数据增强，仅进行尺寸调整与归一化，以保证结果客观稳定。

在上述设置下，我最终在测试集上取得了：Final Test Accuracy：98.81%（0.9881）

此外，我在测试阶段统计了所有样本的预测标签与真实标签，并生成混淆矩阵用于分析类别间的主要混淆关系；同时记录每个 epoch 的训练/验证损失与准确率曲线，用于观察模型收敛过程与泛化情况（对应图片我在报告中另行粘贴）。在训练过程中，我以验证集准确率作为模型选择指标：当某一轮验证准确率超过历史最佳值时，立即保存该轮模型参数为

best_model.pth 。因此，最终测试结果使用的是验证集表现最优的模型权重，而非最后一个 epoch 的权重，从而减少因后期波动导致的评估偏差。我记录每个 Epoch 的训练损失、训练准确率、验证损失与验证准确率，并生成对应的学习曲线（Loss/Accuracy 曲线），用于观察模型是否存在欠拟合/过拟合以及学习率调度是否合理。以上可视化对应的图片文件由程序自动生成，你可按作业要求自行粘贴到报告中。

从方法与模型能力角度而言，采用 ImageNet 预训练的 ResNet18 并结合上述增强与训练策略，在 EuroSAT 这类 10 类遥感分类任务上通常能够取得 显著高于 MLP 基线 的准确率。

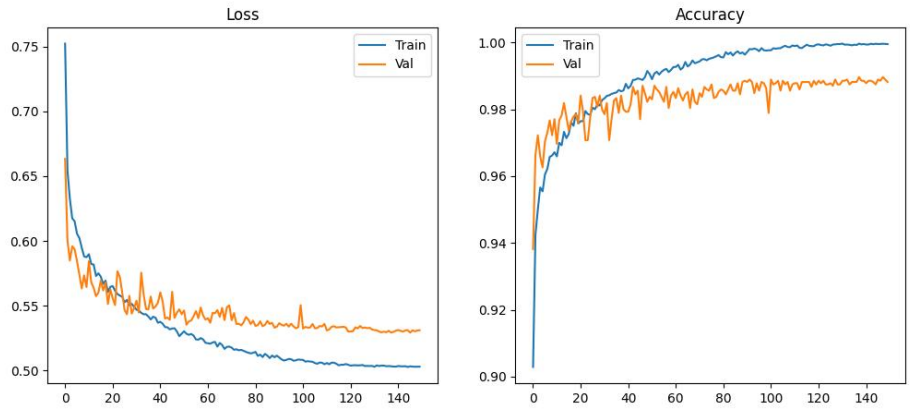

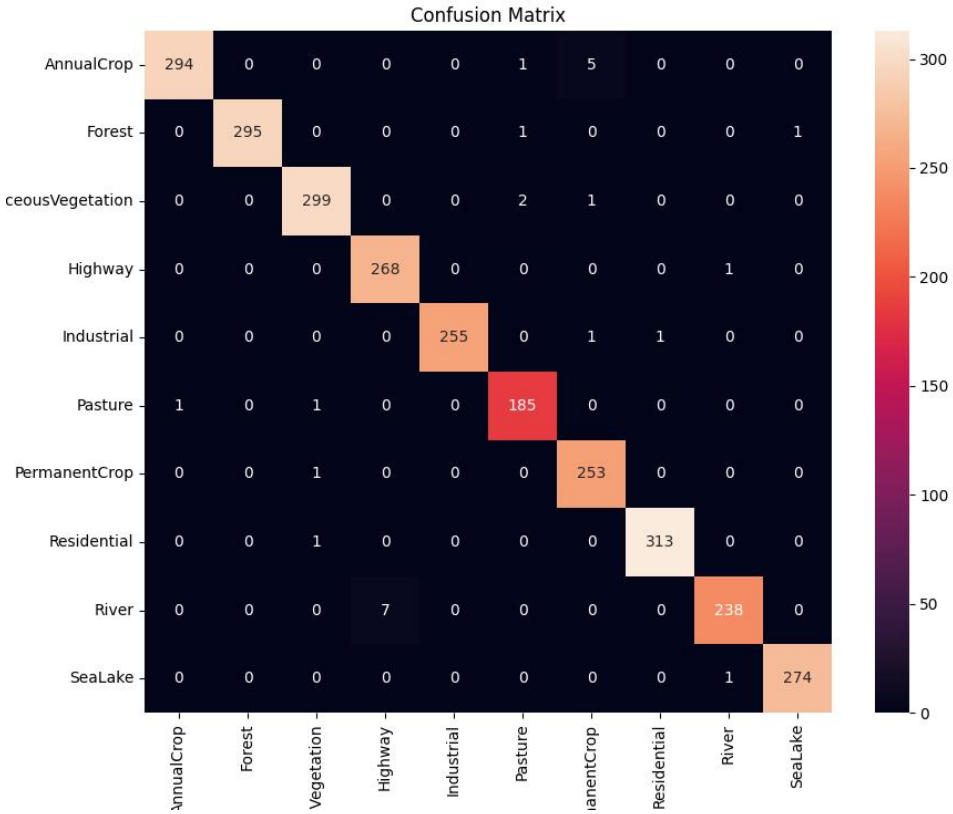

将训练好的第一层隐藏层权重矩阵恢复成图像尺寸，并将其作为图像进行可视化。

神经元的权重图呈现出明显的绿色或蓝色。这表明这些神经元对“森林草地”或“河流湖泊”等特定颜色的像素非常敏感。

虽然 MLP 不像 CNN 那样有明确的局部感受野，但权重图中仍会出现一些点状或条纹状的纹理模式，这说明模型正在尝试捕捉地物的空间分布规律。

First Hidden Layer Weight Visualization (Optimized Model)

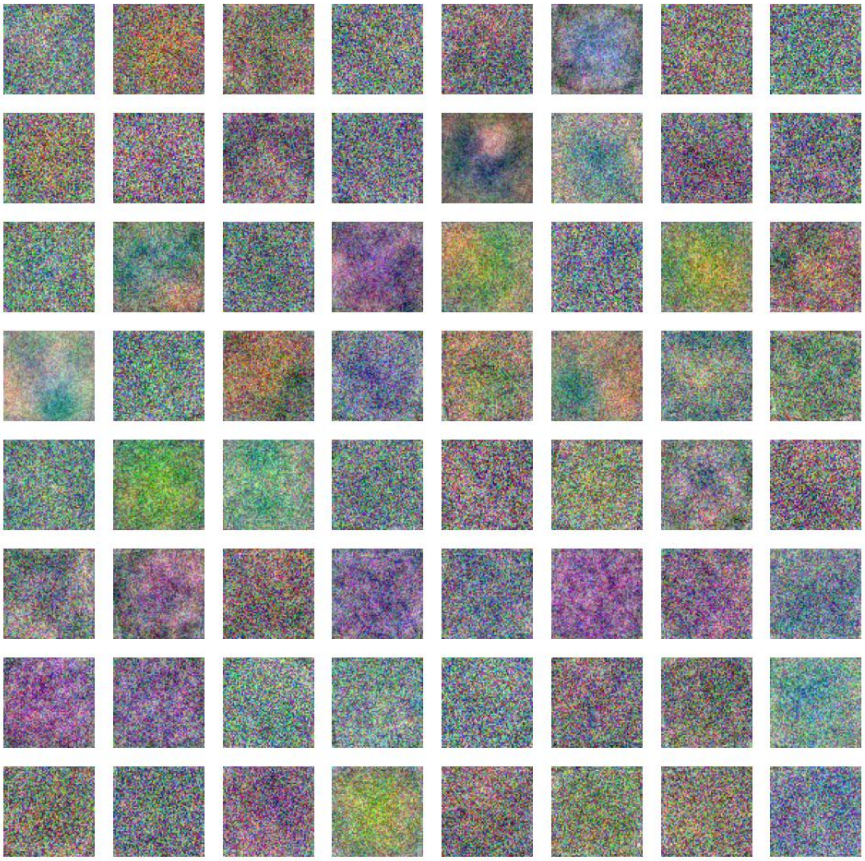

从测试集中挑选出几个分类错误的卫星图像，结合地物特征简单分析其被分错的可能原因。

Misclassified Samples (Optimized Model)

高速公路(Highway)和河流(River)，两者都具有狭长的线性结构。在遥感图像中，深色的河流与柏油路面在像素分布上非常相似。由于 MLP 缺乏捕捉空间连续性（拓扑结构）的能力，它无法区分“笔直的公路”和“弯曲的河流”。
草地(HerbaceousVegetation)和住宅区(Residential)，许多住宅区样本中包含大量的绿化带。当建筑物分布稀疏时，全局颜色特征以绿色为主，导致模型误判为草地。

Github 链接：https://github.com/chen12138-123/HW1-ZXY
GoogleDrive 链接：
第一次提交结果：
https://drive.google.com/file/d/1xRTwHE_bhuTzHQYpZ3VyJ4JNpfIX2m1s/view?usp=drive_link
第二次提交结果：
https://drive.google.com/file/d/1g2zUBGDekzhef4GkCfMiwoE5A_fjo3u5/view?usp=sharing